基于循环和卷积神经网络的质子交换膜燃料电池精确长期预测

Kartik Sahajpal*, K.P.S. Rana, Vineet Kumar

Netaji Subhas University of Technology, 仪器与控制工程系, 印度新德里 Dwarka, Sector-3, 110078

研究亮点

- 开发了六种用于PEMFC剩余使用寿命(RUL)和退化预测的深度学习模型。
- 使用TPE对每种模型的超参数进行静态和动态负载条件下的优化。
- 静态负载模型表现出优异的迁移学习性能。
- 所有调优模型在RMSE指标上均优于近期报道的方法。
- 基于50%数据训练的LSTM和1D-CNN-BidirectionalGRU表现最佳。

摘要

估计质子交换膜燃料电池(PEMFC)的剩余使用寿命(RUL)是预测和提高其耐久性的关键。本文研究了六种深度学习技术——长短期记忆网络(LSTM)、门控循环单元(GRU)、一维卷积神经网络(1D-CNN)-LSTM、1D-CNN-GRU、1D-CNN-双向LSTM和1D-CNN-双向GRU——用于有/无电流纹波的五电芯PEMFC电堆的RUL和长期退化趋势预测。所有模型的超参数通过树状结构Parzen估计器(TPE)结合Hyperband剪枝进行优化，以最小化电堆电压的均方根误差(RMSE)。预测结果使用决定系数(R^2)、RMSE、平均绝对百分比误差(MAPE)以及RUL估计的相对误差(RE)进行基准测试。对50%数据集训练的模型进行的比较分析表明：对于无电流纹波的电堆，LSTM模型给出的最佳R^2、RMSE、MAPE和RE分别为98.87E-2、1.258E-3、0.285E-1和0.0425E-1。对于有电流纹波的电堆，1D-CNN-双向GRU模型给出最佳R^2、RMSE、MAPE和RE分别为99.482E-2、1.77E-3、0.444E-1和0.089E-1。LSTM模型在对有电流纹波的电堆进行迁移学习时也表现出优异的性能，最佳R^2、RMSE、MAPE和RE分别达到98.91E-2、2.455E-3、0.362E-1和0.044E-1。

1. 引言

质子交换膜燃料电池(PEMFC)是电动汽车[1]和发电厂[2]潜在的零排放商用可再生能源。PEMFC没有运动部件，因此相比化石燃料动力系统具有更高的能量转换效率、更快的启动速度和更低的噪声。PEMFC通过氢与氧在铂催化剂上的电化学反应产生电能，如图1所示。然而，由于使用寿命短(约1500-2000小时)[3]和高成本[4]，其应用目前仅限于小规模以及军事和汽车行业。在这些应用中，需要设计智能自适应控制方案来调节气体流量等输入变量，以最大化PEMFC系统的高效稳定运行[5-7]。对于电动汽车等大规模工业应用，至少需要6000小时的使用寿命[8]。近期研究表明，估计平均故障时间或剩余使用寿命(RUL)有助于提前选择维护措施和最优运行条件，从而提高PEMFC的耐久性[8,9]，并进一步减少不可预见的故障和计划外维护，从而降低资源消耗、环境废物和维护成本。RUL估计或预测还可以在不长期实际运行PEMFC的情况下预测其未来健康状态，进一步节省时间和成本。因此，结合预测后决策，RUL估计是一种强大的技术，有助于最大化PEMFC供电系统的使用寿命。

[图1 - PEMFC简化操作示意图]

PEMFC的RUL取决于输出电压和功率的退化动态，这些动态又依赖于各种运行因素，如负载条件和使用工况。根据Pei等人[10]的研究，PEMFC的重要运行条件包括启停循环、高功率负载、负载变化循环和怠速条件。他们的分析表明，负载变化(动态负载)和启停循环分别占PEMFC电压退化的56.5%和33%。文献[11,12]也分析了动态负载和启停循环对PEMFC电压退化的影响。研究表明，在启停和动态负载下，催化剂降解、热管理不良导致的热失控、膜变薄和分解、碳腐蚀、催化剂中毒以及扩散应力显著导致PEMFC的退化[13]。已有几篇综述回顾了PEMFC供电系统中各种退化机制的建模方法[14]。但无论采用何种建模方法，都需要一个与PEMFC退化程度良好相关的退化指标来定量估计其RUL[13,14]。最常用的指标是其输出电压和功率，也有一些研究使用电化学活性表面积[15]或退化指标组合[16]来估计PEMFC的RUL。

估计PEMFC供电系统的RUL需要对PEMFC的多个参数进行广泛的时间测量，以设计、验证和测试RUL估计器的预测性能。近期PEMFC预测文献主要基于公开可用的IEEE 2014 Prognostics and Health Management (PHM)数据挑战数据集，该数据集由法国FCLAB研究联盟提供[17]。该数据集来自在法国FCLAB研究联盟FR CNRS 3539测试平台上对两个五电芯PEMFC电堆进行的约7周实验。测量参数包括电芯和电堆电压、电流、气体流量、温度、湿度等，总结于表1。第一个电堆FC1在70 A负载电流下运行1155小时。第二个电堆FC2在70 A负载电流外加7 A、5 kHz三角电流纹波下运行1021小时。FC2中的电流纹波模拟连接到电堆输出的功率变换器，代表PEMFC的动态或准动态运行。

除了IEEE PHM 2014数据挑战数据集外，很少有长期测量实验被报道，且并非全部公开。例如，Zuo等人[18]对PEMFC单电池进行了1008小时的动态耐久性测试，建立了基于门控循环单元(GRU)和长短期记忆(LSTM)网络的深度学习预测模型，并评估了有无注意力机制的循环神经网络(RNN)的预测性能。另一项研究[19]在电动汽车用28电芯开路阴极PEMFC系统上进行了5000小时变环境温度耐久性测试，基于ESN的退化预测模型在超过2000小时的预测时间框架内实现了0.098的归一化RMSE。

文献中可以识别出三种PEMFC预测方法——基于模型的方法、数据驱动方法和混合方法[8,9]。基于模型的方法使用物理或经验模型，通过一组代数/积分微分方程描述PEMFC的动态和退化。基于模型方法的一个显著优点是不需要大量实验测量或经验数据。例如，Zhang等人[20]提出了一种基于电堆电压和健康状态作为退化指标的两个基于物理的退化模型的集成。PEMFC内阻和开路电压的退化估计健康状态，而RUL则通过粒子滤波器进行联合状态参数估计来预测。Chen等人[21]提出了三种电压退化模型和无迹卡尔曼滤波器来预测用于邮政电动车的现场运行PEMFC的退化。另一种方法使用混合指标(电堆电压、功率和内阻)，通过二阶高斯退化模型和无迹粒子滤波器预测FC1的退化趋势[22]。然而，由于PEMFC的确切退化机制尚未完全理解且退化发生在多个时间和空间尺度上，精确的退化模型难以建立。基于模型的预测方法通常对系统的物理机制和退化过程本质做出假设，如果这些假设不正确或不完整，模型可能无法准确预测RUL和退化趋势。此外，基于模型的方法通常计算复杂，不适合在线RUL预测[9]。

数据驱动方法利用对PEMFC的测量来建立黑箱模型描述其退化动态。机器学习、深度学习等数据驱动方法不需要PEMFC系统的物理或经验模型，因此可以轻松建模非线性特性，并仅从输入输出数据准确预测退化趋势，而无需对PEMFC系统的退化动态做出假设。例如，LSTM网络在多变量时间序列数据集(包括FC1和FC2)上表现出优异的预测性能[23-26]。Zuo等人[23]提出了一种LSTM网络退化模型，在Savitzky-Golay平滑后预测FC1的退化趋势，并在FC2上验证了模型性能。另一项研究中，采用随机森林特征提取后，带有注意力机制的LSTM和双向LSTM模型[24]在FC1和FC2上训练，实现了约0.09%-0.29%的相对预测误差。双向LSTM还与GRU结合，利用回声状态网络(ESN)仅使用FC1和FC2数据集的五分之一进行短期退化预测[25]。Wang等人[26]提出了堆叠LSTM与注意力、支持向量回归和随机森林的集成模型(AT-LSTM-SVR-RF)，通过差分进化优化，用于FC1和FC2的RUL和长期退化预测。

除RNN外，卷积神经网络(CNN)由于能够捕获多变量时间序列中的复杂退化模式，在预测文献中也受到越来越多的关注。例如，Huo等人[27]基于140条I-V极化曲线数据集，使用随机森林算法选择特征并建立CNN预测模型来预测PEMFC的I-V极化曲线。Benaggoune等人[28]报道了在FC1和FC2上使用基于注意力的膨胀CNN进行多步提前预测以及使用条件CNN进行长期预测，获得了较高的长期退化趋势预测精度。最近，RNN和CNN被结合起来，在长期退化趋势预测方面取得比单独RNN或CNN更好的精度。例如，文献[29]展示了CNN-双向LSTM网络架构用于FC1和FC2的长期退化趋势预测和RUL估计。Tao等人[30]报道了另一种深度学习架构，即二维CNN与GRU网络结合，并通过蝠鲼觅食优化器进行优化，用于PEMFC系统的性能退化预测。

混合方法融合基于模型和数据驱动方法以获得更好的预测精度，在RUL估计中最近才引起研究兴趣。Cheng等人[31]提出了一种混合预测方法，结合数据驱动的最小二乘支持向量机模型和基于模型的正则化粒子滤波方法，估计FC1的RUL及其概率分布。另一种混合预测模型[32]使用自适应无迹卡尔曼滤波器进行老化状态估计，以及粒子群优化(PSO)-自适应神经模糊推理系统框架，探索了FC1和FC2的长期退化预测。自适应卡尔曼滤波器也与经验老化模型结合，并混合非线性自回归外生模型，预测FC1和FC2的可逆和不可逆退化趋势[33]。文献[32,33]都研究了不同训练集大小对混合模型预测性能的影响。但混合方法需要实验数据和对物理退化规律的了解，而且混合模型常常累积数据驱动和基于模型方法的优缺点[9]。关于PEMFC RUL估计各种方法的详细综述可参考文献[34,35]。

深度学习是一种数据驱动的预测技术，在容易出现运行故障的系统的可靠性分析、预测和健康管理方面越来越受到关注[36,37]。至少具有两层的神经网络(深度神经网络)在数学上模拟人类神经元，并在两个阶段模拟人类学习过程。在PEMFC RUL预测的背景下，第一阶段是学习阶段，使用预测区间之前记录的测量值训练神经网络，使网络更新其参数以最佳拟合PEMFC的退化行为。在预测阶段，神经网络使用学习到的权重预测PEMFC在预测时间之后的退化趋势。Wang等人[38]提出了一种LSTM模型，由自回归积分移动平均外生变量模型生成的导航序列驱动，用于静态负载下的96电芯PEMFC电堆和动态负载下的15电芯PEMFC电堆。Meraghni等人[39]提出了一种数字孪生堆叠自编码器，用于具有1750小时电压测量的五电芯PEMFC电堆的RUL和退化趋势预测。利用电堆

电压、电流、温度和反应气体压力测量值，多输入ESN也被报道用于预测FC1和FC2的RUL[40]。

深度学习模型的预测性能取决于多个超参数，这些超参数决定了模型对新的未见数据的泛化能力。超参数一般包括神经网络激活函数、神经元数量和隐藏层数。手动调整这些参数以获得最佳预测结果实际上并不可行，因为超参数值与模型预测精度之间的确切关系尚不清楚。为了达到最优预测性能，需要搜索一组能最小化期望代价函数的超参数。这在PEMFC预测文献中通过传统网格搜索技术、元启发式方法(如进化算法和群体智能技术)或序贯设计方法来解决。网格搜索[18]评估搜索空间中每个可能的超参数组合以找到最佳模型，因此计算效率低，尤其当神经网络训练时间较长时。此外，它不会在评估试验之间传递信息以排除超参数空间中预测性能差的区域。另一方面，遗传算法、粒子群优化(PSO)、灰狼优化器(GWO)等元启发式算法引导搜索过程生成、调整或找到最小化期望代价函数的启发式信息[26,30,31,37]。Chen等人[41]报道了一种反向传播神经网络，其超参数通过思维进化算法、PSO和遗传算法进行优化，用于FC1的老化预测。Li等人采用改进的GWO算法在验证阶段优化核极限学习机预测器的超参数[42]。然而，如果引导不当，随着目标数量和搜索空间维度的增加，种群搜索算法的计算成本可能呈指数增长[43]。智能超参数选择器(如基于贝叶斯优化的选择器[44])会只关注那些能优化目标函数(如最小化RMSE或MAPE)的区域，且计算工作量更小。贝叶斯优化器在锂离子电池[45,46]和旋转机械轴承[47]的退化预测中已表现出优异的性能。

基于上述文献综述，可以推断深度学习技术是PEMFC的RUL和长期退化预测的有力候选方法。因此，受上述观察的启发，本文探索了一种基于深度学习的方法，采用树状结构Parzen估计器(TPE)——一种改进的贝叶斯优化器——进行超参数调优，以开发静态和动态负载条件下PEMFC的退化预测和RUL估计模型。电流纹波的存在与否模拟了静态和动态负载条件。所提出的PEMFC退化模型在IEEE PHM 2014数据挑战数据集FC1和FC2上开发和验证。本文探索了六种具有循环和卷积层的深度神经网络模型在五电芯PEMFC电堆剩余使用寿命估计方面的效率。选择电堆电压作为退化指标。本文的主要贡献总结如下：

- 研究了六种用于预测静态和动态负载条件下PEMFC的RUL的深度学习模型：LSTM、1D-CNN-LSTM、1D-CNN-双向LSTM、GRU、1D-CNN-GRU和1D-CNN-双向GRU。
- 使用树状结构Parzen估计器(TPE)和Hyperband剪枝进行超参数优化，以获得每种模型在两种负载条件下的最佳性能。
- 对比分析了所提模型与各种混合以及纯循环和卷积神经网络在RUL估计方面的性能。预测结果表明，本文提出的所有深度学习模型在退化趋势和RUL预测性能方面均优于现有文献中报道的深度学习模型。
- 每个在FC1数据集上训练的深度学习模型都能准确预测FC2的退化趋势和RUL，展现出优异的迁移学习能力。
- 所提出的预测方法适用于PEMFC供电设备的在线RUL估计和长期退化趋势预测。

本文组织结构如下：第2节介绍了六种预测模型的架构和用于性能基准测试的损失函数；第3节简要介绍了所提预测策略的实施；第4节分析了在FC1和FC2数据集上训练的

六种模型的长期退化趋势和RUL预测结果，以及在FC1上训练的模型对FC2的迁移学习性能；第5节总结了研究结果并提供了未来研究方向。

2. 基于深度学习的退化预测模型

本节介绍所开发的深度学习模型架构，并简要描述TPE优化器。

2.1 深度学习架构

本节介绍两种被研究的神经网络架构——RNN和CNN。

2.1.1 循环神经网络(RNN)

RNN可以使用内部状态变量作为记忆来建模固定和可变长度的序列（如语音和时间序列）。LSTM网络是一种改进的RNN架构，解决了传统RNN中的梯度消失和梯度爆炸问题。LSTM已广泛应用于语音、文本、自然语言处理和时间序列预测[48]。LSTM由记忆块而不是神经元组成，如图2(a)所示。每个记忆块包含一个或多个细胞，每个细胞有一个输入门\(\mathbf{i}_1 \)、遗忘门\(f_t \)和输出门\(\mathbf{o}_t \)。LSTM细胞在时间\(t \)的内部状态为\(\mathbf{c}_t \)。遗忘门遗忘来自先前时间步的不相关训练数据。

[图2 - (a) LSTM细胞; (b) GRU细胞]

LSTM的控制方程如下：

$$\mathbf{i}_t = \sigma (W_{xi}\mathbf{x}_t + W_{hi}\mathbf{h}_{t-1} + \mathbf{b}_i) \quad (1)$$

$$f_t = \sigma (W_{xf}\mathbf{x}_t + W_{hf}\mathbf{h}_{t-1} + \mathbf{b}_f) \quad (2)$$

$$\mathbf{c}_t = f_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tanh(W_{xc}\mathbf{x}_t + W_{hc}\mathbf{h}_{t-1} + \mathbf{b}_c) \quad (3)$$

$$\mathbf{o}_t = \sigma (W_{xo}\mathbf{x}_t + W_{ho}\mathbf{h}_{t-1} + \mathbf{b}_o) \quad (4)$$

$$\mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{c}_t) \quad (5)$$

GRU[49]是一种RNN，与LSTM略有不同：每个记忆块中具有更新门、重置门和输出门。LSTM的输入门和遗忘门在功能上合并为GRU的更新门，如图2(b)所示。重置门决定是否忽略过去的隐藏状态。更新门\(z_t \)和重置门\(r_t \)的输出方程如下[50]：

$$z_t = \sigma (W_{xz}x_t + W_{hz}h_{t-1} + b_z) \quad (6)$$

$$r_t = \sigma (W_{xr}x_t + W_{hr}h_{t-1} + b_r) \quad (7)$$

$$\tilde{h}_t = \tanh(W_{xh}x_t + W_{hh}(r_t \odot h_{t-1}) + b_h) \quad (8)$$

$$h_t = z_t \odot h_{t-1} + (1 - z_t) \odot \tilde{h}_t \quad (9)$$

图2所示的LSTM和GRU网络仅沿正向处理输入序列。将隐藏层中的神经元划分为两组——一组正向处理序列，另一组反向处理序列——就构成了双向循环神经网络。将这两组正反向处理网络连接到同一个输出层可以提高预测性能。双向模型可以利用过去和未来的上下文来学习长期依赖和双向趋势。因此，双向LSTM[51]和GRU[52]近年来在预测和预测性维护应用中受到越来越多的关注。

2.1.2 卷积神经网络(CNN)

CNN处理具有网格结构的数据，如时间序列和图像。典型的CNN由卷积层、池化层和输出层组成。卷积层通过将输入数据\(x_t \)与可学习的固定长度核（滤波器）\(k_t \)进行卷积来提取特征图，核以预设步长在输入数据上滑动。这些层计算输入数据的一部分与相同大小的重叠滤波器的点积，然后通过非线性激活函数\(f \)传播卷积结果，生成第\(k \)层的输出特征图\(h_k \)：

$$h_k = f(\omega_k * x + b_k) \quad (10)$$

其中\(w_k \)和\(b_k \)分别是卷积层的滤波器权重和偏置。卷积层之后可以跟池化层，尤其在计算机视觉应用中，通过选取每个滤波器操作的最大值（或平均值）来降低特征图采样率。池化可能降低每轮训练时间并有助于通过聚焦于主要特征避免过拟合，但对于具有微小和不规则关键特征的数据集可能表现不佳。此外，池化使CNN仅学习位置或平移不变的特征，可能丢弃特征中重要的时间信息[53]。本文中的CNN没有池化层，且带有CNN和循环层的模型将卷积层的输出馈送到循环层。

2.2 基于树状结构Parzen估计器和Hyperband剪枝的超参数优化

TPE算法是一种改进的贝叶斯优化器，最近被报道用于核电厂蒸汽发生器长期预测模型的超参数优化[54]。贝叶斯优化使用目标函数的高斯过程模型，特别适用于目标函数\(f \)计算代价高昂的情况。考虑超参数集\((\theta_t) \)的历史以及每个超参数集评估的目标函数值\((y_t) \)捆绑为向量\(X = \{(\theta_t, y_t), \dots, (\theta_{t-1}, y_{t-1})\} \)。贝叶斯优化将\(f \)建模为\(p(X) \)，并使用采集函数选择下一个超参数集，该函数在超参数搜索空间中的高随机性区域（探索）和最优值区域（利用）之间取得平衡。贝叶斯优化迭代采样下一个最大化\(a(\theta) \)的\(\theta \)，即\(\theta_{t+1} = \arg\max_{y\in \mathbb{Z}} a(\theta) \)，评估\(y_{t+1} = f(\theta_{t+1}) \)，并将\((\theta_{t+1}, y_{t+1}) \)附加到\(X \)。然后在每次采样试验后更新概率模型\(p(f|X) \)。迭代持续直到满足停止准则（如固定试验次数或时间限制）。

TPE算法使用以现有数据点为中心的核平均来估计高斯过程模型的概率密度，而不是评估\(p(X) \) [55]。与最优和差劲超参数集相关的核密度估计量分别给出：

$$l(\theta) = p(y < y^* \mid \theta, X), \quad g(\theta) = p(y > y^* \mid \theta, X) \quad (11,12)$$

带Hyperband剪枝的TPE伪代码如图3所示。其中\(M_i \)是在第\(i \)次试验中拟合的目标函数\(f \)的计算代价较低的代理函数，\(N \)是试验次数，\(\theta^* \)是使采集函数

（即期望改进EI）最小的超参数集。EI是在\(M \)下对\(f \)的期望，即\(f(\theta) \)负向超过阈值\(y^* \)：

$$\[EI_{y^*}(\theta) = \int_{-\infty}^{y^*} (y - y^*) p(y|\theta) dy \quad (13) \]$$

$$\[EI_{y^*}(\theta) = \int_{-\infty}^{y^*} (y - y^*) \frac{p(\theta|y)p(y)}{p(\theta)} dy \quad (14) \]$$

[图3 - TPE与Hyperband剪枝算法的伪代码]

TPE选择\(\gamma = p(y

$$\[EI_{y^*}(\theta) \propto \left(\gamma + \frac{g(\theta)}{l(\theta)}(1-\gamma) \right)^{-1} \quad (16) \]$$

因此TPE最大化比值\(l(\theta)/g(\theta) \)，即最大化\(l(\theta) \)并最小化\(g(\theta) \)。Hyperband剪枝器通过动态资源分配自动停止预测性能差的搜索试验，并考虑固定的计算预算（如训练轮数）。Hyperband类似于可变早停策略：如果某个超参数配置的模型收敛到差解（低精度）则中断训练，如果模型性能改善（高精度）则延长训练。由于Hyperband使用随机搜索选择超参数配置，试验之间没有信息传递来指导超参数选择器。本文采用TPE代替随机搜索，在每个试验中选择超参数配置。

3. 预测策略

本节详细介绍了应用于数据集的数据预处理步骤、用于评估预测结果的损失函数和评估指标，以及模型开发和验证工作流程。

3.1 数据预处理

FC1数据集包含143,862个数据点，FC2数据集包含127,370个数据点。为降低处理数据的计算复杂性同时保留PEMFC的退化特性，两个数据集中的所有测量值均以1小时间隔重新采样，得到FC1的1155个数据点和FC2的1021个数据点。FC1的电堆电压显示出不规则和噪声模式，而由于动态负载条件，FC2的电堆电压显示出明显的尖峰。为减少高频噪声并平滑所得数据集，对FC1和FC2数据集均应用了窗口长度（系数个数）为21的二阶Savitzky-Golay滤波器(SGF)。SGF是一种有限脉冲响应数字滤波器，通过线性最小二乘法拟合低阶多项式来平滑序列[57]。FC1和FC2的原始（原始）、降采样和滤波后的电堆电压分别示于图4(a)和4(b)-4(c)。值得注意的是，本文选择SGF而不是PEMFC预测文献中常用的局部加权散点平滑法(LOWESS)，因为与SGF不同，LOWESS对异常值敏感，并且需要密集采样的数据集才能产生令人满意的去噪输出[61]。

[图4 - (a) FC1的原始、采样和滤波电压；(b) FC2原始电压；(c) FC2降采样和滤波电压]

接下来，确定用于估计RUL的故障阈值。故障阈值决定了PEMFC电堆无法提供足够运行电压的故障点。因此，PEMFC电堆的RUL是电堆能够提供大于或等于其故障阈值的输出电压的时间。FC1和FC2的故障阈值选定为经过SGF后在0小时电堆电压的96%。选择96%的故障阈值与近期PEMFC预测文献[25,26,28,59]一致。FC1和FC2的故障阈值分别计算为3.2028 V (=0.96×3.3362 V)和3.1971 V (=0.96×3.3303 V)。值得注意的是，SGF的窗口长度和阶数会影响平滑后的电堆电压，从而影响故障阈值。

为了使用监督式深度学习模型进行RUL估计，需要将时间序列数据集转化为监督学习问题。时间序列包含按时间索引的数据，而监督学习问题由输入和输出模式组成，使得机器学习模型可以根据输入模式预测输出。通过将每个特征向后移动一个或多个时间步来创建滞后观察列，将时间序列数据集转换为适用于监督学习的数据集。在这里，每个电堆测量值滞后一个时间步。因此，添加一个时间步滞后后，FC1和FC2的新数据集长度分别为1154小时和1020小时。采用表1中列出的24个特征来训练所开发的深度学习模型。由于特征数量相对较少，且最优特征重要性阈值依赖于数据集统计数据[62]，因此未进行特征选择。然后，将FC1和FC2数据集按50:10:40的比例划分为训练集、验证集和测试集。验证集对于独立于训练和测试数据评估模型性能是必要的。FC1数据集的训练、验证和测试集长度（小时）分别为577小时、115小时和462小时；FC2数据集分别为510小时、102小时和408小时。验证间隔的选择使得PEMFC电压仅在验证持续时间之后才降至其故障阈值以下。如果预测从时间$t_{\text{predicted}}$开始，实际故障或寿命终止阈值在时间t_{failure}达到，则实际RUL$\text{RUL}_{\text{actual}}$为：$\text{RUL}_{\text{actual}} = t_{\text{failure}} - t_{\text{predicted}}$ (17)。预测RUL$\text{RUL}_{\text{predicted}}$由预测故障阈值时间$\hat{t}_{\text{failure}}$与预测时间之差给出：$\text{RUL}_{\text{predicted}} = \hat{t}_{\text{failure}} - t_{\text{predicted}}$ (18)。根据平滑数据集，验证和训练间隔后FC1和FC2的真实RUL分别计算为235小时和225小时。因此，FC1和FC2的有效使用寿命分别为927小时和837小时。

训练集、验证集和测试集使用最小-最大归一化进行标准化。在数据集划分之前进行归一化可能导致数据泄漏，因为训练集的统计信息（如均值和方差）可能泄漏到测试集和验证集中，这可能导致模型在面对未见数据时性能评估出现潜在偏差。因此，在将数据集划分为训练集、测试集和验证集之后进行归一化。使用最小-最大归一化方程将训练集中的所有特征和电堆电压缩放到(0,1)范围：$\overline{x} = \frac{x - \min(x)}{\max(x) - \min(x)}$ (19)。验证集和测试集使用训练集相应特征的最小值和最大值进行归一化。尽管这样做可能不会将测试集和验证集特征缩放到(0,1)范围，但这允许无偏的模型性能评估。

3.2 损失函数和评估指标

每个模型的预测性能使用三个长期退化预测指标进行基准测试——决定系数(R^2)、均方根误差(RMSE)和平均绝对百分比误差(MAPE)——以及RUL估计的相对误差(RE)。预测精度高的模型显示高R^2（接近1）和低RMSE、MAPE和RE。将平滑数据集中的电压数记为n，原始电堆电压为x_i，预测电堆电压为$\hat{x}_i$，原始电堆电压的平均值为$\overline{x}_i$，指标R^2、RMSE和MAPE定义为：

$$R^2 = 1 - \frac{\sum (x_i - \hat{x}_i)^2}{\sum (x_i - \overline{x}_i)^2} \quad (20)$$

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(x_i - \hat{x}_i)^2} \quad (21)$$

$$MAPE = \frac{100}{n}\sum_{i=1}^{n}\left|\frac{x_i - \hat{x}_i}{x_i}\right| \% \quad (22)$$

$$RE = \frac{RUL_{\text{actual}} - RUL_{\text{predicted}}}{RUL_{\text{actual}}} \quad (23)$$

在TPE超参数优化中，选择RMSE作为损失函数；而训练每个神经网络模型的损失函数选择为平均绝对误差(MAE)，定义如下：

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|x_i - \hat{x}_i| \quad (24)$$

当PEMFC连接到动态负载时，可能发生大的电堆电压波动，这些波动可能依赖于负载的性质。这些波动可能在训练和验证阶段结束时或测试阶段随机出现，导致RUL误判。为避免RUL误判，每个模型的预测结果在50次训练迭代上取平均，而不是仅依赖单次训练迭代的结果。此外，由于神经网络采用随机初始化的权重，统计平均对于提取所开发模型预测精度的有价值见解是必要的。另外，每次训练迭代中重置每个模型的初始状态，使得模型不会在每次迭代中对训练、验证和测试集拟合相同的权重和偏置。

3.3 模型开发和验证

使用开源Keras库[63]（TensorFlow后端2.9.2版）的神经网络实现来构建预测模型。所有模型均在NVIDIA DGX A100 GPU上训练以加速模型训练。实现所提模型的代码可在GitHub上获取：https://github.com/kar10tik/LongTerm-PEMFC-DL-Prognostics。训练过程中通过dropout正则化和早停策略防止过拟合。过拟合发生在模型在训练集上表现出优异的预测精度但在测试集上表现不佳时，因为模型记住了训练集数据而不是拟合它们。Dropout在训练过程中随机丢弃神经元及其连接以防止过拟合。早停策略中，当验证损失在固定轮数（称为耐心值）内没有改善时停止训练。耐心值指定了验证损失没有观察到改善的轮数，之后模型停止训练。Dropout被选为待优化的超参数，每个模型训练150轮，早停耐心值为30。

为了快速收敛预测结果，探索了三种基于梯度的神经网络优化器的预测性能：随机梯度下降(SGD)、均方根传播(RMSprop)和Adam。SGD[64]是一种基于梯度的优化器，从数据的随机部分而不是整个数据集计算目标函数的梯度。该算法遵循目标函数的负梯度来定位其全局最小值。RMSprop优化器[65]使用部分梯度的衰减平均值来修改每个参数的步长，以便优化器忘记早期梯度，专注于最近观察到的部分梯度。自适应矩估计优化器Adam[66]是RMSprop的一种变体，使用基于梯度指数加权平均调整的可变学习率。然而，神经网络模型的最佳优化器取决于网络架构和用于训练网络的数据集。

[图5 - 所提基于深度学习的预测方法的实现流程]

图5描述了所提模型的实现工作流程。使用Python中Optuna[67]开源实现的带Hyperband剪枝的TPE来优化预测模型。每个模型训练500次试验，每次试验中采用早停策略，耐心值为30。每个模型的dropout搜索范围[0.01, 0.5]，优化器在{SGD, Adam, RMSProp}中搜索。SGD和Adam优化器的学习率在对数间隔范围[1E-5, 1E-1]中搜索。对于SGD优化器，动量在对数间隔范围[1E-3, 99E-2]中搜索。对于RMSprop优化器，衰减参数在对数间隔范围[0.85, 0.99]中搜索。对于LSTM和GRU模型，最优隐藏层数（即LSTM或GRU层数）在[1,10]中搜索。每个隐藏层的神经元或单元数在[30,100]中搜索，每个隐藏层的激活函数设置为tanh。对于1D-CNN-LSTM、1D-CNN-GRU、1D-CNN-双向LSTM和1D-CNN-双向GRU模型，卷积层的激活函数在{'tanh','softmax','relu'}中搜索，卷积滤波器数量在[30,100]中搜索。对于这些模型，神经元数量在[30,110]中搜索。模型开发和验证工作流程总结如下：

1. 以1小时间隔对FC1和FC2数据集降采样，然后使用窗口长度为21的二阶SGF进行平滑和去噪。
2. 通过将测量值滞后一个时间步，将两个数据集转换为监督学习问题，得到24个特征（t-1时刻的电堆测量值）和一个待预测的因变量（t时刻的总电堆电压）。
3. 按50:10:40的比例将两个数据集划分为训练集、验证集和测试集，然后使用各自训练集中每个特征的最小值和最大值进行最小-最大归一化。
4. 使用归一化的训练和验证数据集以及MAE作为损失函数，分别针对FC1和FC2开发两组六个模型。
5. 定义超参数搜索空间如上。运行500次试验以优化每个模型的超参数，退化趋势预测的损失函数为RMSE。每次试验中，模型训练150轮，早停耐心值为30。
6. 对于FC1和FC2，使用优化后的超参数在测试数据上测试模型，并将预测结果在50次试验上取平均。
7. 测试FC1上优化后的模型在FC2数据集上的预测性能，并将预测结果在50次试验上取平均。

4. 预测结果与讨论

本节展示了超参数优化结果、每个模型在FC1和FC2数据集上的预测性能，以及FC1训练模型对FC2的迁移学习性能。

4.1 超参数优化结果

在定义的超参数搜索空间上，通过TPE和Hyperband剪枝进行500次搜索试验，找到的超参数配置列于表2（FC1）和表3（FC2）。有趣的是，LSTM和GRU模型的最优隐藏层数对于FC1和FC2数据集均为1。对于所有评估模型，包括卷积层的最大隐藏层数为2。对于LSTM和GRU模型，将隐藏层数增加到超过2会导致计算复杂度高且预测性能差。由于每层的单元数也被视为超参数，超参数搜索空间随着隐藏层数的增加而增加。有趣的是，对于所有模型，FC1和FC2数据集的最佳激活函数和最佳优化器都是tanh和Adam。对于FC1训练的模型，最优dropout范围为0.06至0.31；对于FC2训练的模型，最优dropout范围为0.01至0.09。FC1训练模型的最优学习率范围为1.20E-4至6.90E-4，FC2训练模型的最优学习率范围为1.80E-4至4.05E-4。计算所有评估模型的最佳超参数配置的平均时

间为2小时。然而，大多数模型在约1.25小时内（完成近300次试验时）就收敛到了接近最佳超参数配置的RMSE。因此，当从PEMFC系统获得约一半退化数据后，大约300次试验可用于在线模型优化。

[表2 - FC1数据集训练模型的最优超参数值]

[表3 - FC2数据集训练模型的最优超参数值]

4.2 FC1的预测结果

FC1训练模型的训练、验证和测试间隔分别为577小时、115小时和462小时。图6所示的预测结果表明，在FC1上训练的六种模型的预测电压曲线均能准确跟随电堆电压的变化，提前提供了有关电堆电压退化趋势的重要见解。表4给出了测试数据集的RMSE、MAPE、R^2、预测RUL和RUL预测的RE。对于FC1，LSTM和GRU模型显示出最佳平均RMSE为2.815E-3。GRU模型还表现出最佳平均RUL估计RE为0.055E-1。1D-CNN-LSTM模型表现出最佳平均R^2和MAPE，分别为93.50E-2和0.623E-1。LSTM模型展示了最佳最小RMSE 1.258E-3、MAPE 0.285E-1和最大R^2 98.87。最佳最小RUL预测RE 0.0由GRU、1D-CNN-LSTM、1D-CNN-GRU和1D-CNN-双向GRU模型展示。LSTM、1D-CNN-GRU和1D-CNN-双向LSTM模型的最大预测RUL为577小时，意味着在一次或多次试验中，预测电压在整个预测间隔内未降至3.2028 V (96%)阈值以下。此外，在LSTM和GRU模型上添加CNN层后平均RMSE增加。然而，1D-CNN-LSTM模型的平均MAPE低于LSTM模型，而1D-CNN-GRU模型的平均MAPE高于GRU模型。1D-CNN-双向LSTM和1D-CNN-双向GRU模型也显示出比LSTM和GRU模型更高的平均RMSE和MAPE以及更低的平均R^2。然而，1D-CNN-LSTM模型显示出比LSTM模型更低的RUL预测RE，而1D-CNN-GRU模型显示出比GRU模型更高的RUL预测RE。最接近实际RUL(235 h)的平均预测RUL由GRU模型(236.26 h)展示。LSTM模型在FC1上直接训练和对FC2迁移学习的RMSE(V)、MAPE、MAE(V)和R^2如图7所示。

[图6 - FC1的预测电堆电压曲线]

[表4 - FC1数据集在50次迭代上的预测结果(真实RUL=235h)]

[图7 - LSTM模型在FC1上直接训练和对FC2迁移学习的RMSE、MAPE、MAE、R^2]

4.3 FC2的预测结果

FC2训练模型的训练、验证和测试间隔分别为510小时、102小时和408小时。图8所示的预测结果表明，在FC2上训练的六种模型的预测电压曲线均能准确跟随电堆电压的变化。测试数据集的RMSE、MAPE、R^2、预测RUL和RUL预测RE见表5。在FC2训练的所有模型中，GRU模型显示出最佳平均RMSE为3.348E-3，而LSTM模型显示出最佳平均MAPE、RUL估计RE和R^2，分别为0.837E-1、1.235E-1和97.99E-2。1D-CNN-双向LSTM模型显示的平均R^2为97.98E-2，与LSTM模型相当。1D-CNN-双向GRU模型在FC2上直接训练和对FC1训练的迁移学习的RMSE(V)、MAPE、MAE(V)和R^2如图9所示。1D-CNN-双向GRU模型显示出最佳最小RMSE 1.776E-3和最大R^2 99.48E-2。1D-CNN-双向LSTM模型显示出最佳最小MAPE 0.423E-1。LSTM、GRU、1D-CNN-LSTM和1D-CNN-GRU模型展示了最佳最小RUL预测RE 0.044E-1。在LSTM和GRU模型上添加CNN层后，平均RMSE、MAPE和RUL预测RE增加，平均R^2降低。因此，1D-CNN-LSTM和1D-CNN-GRU模型显示出比LSTM和GRU模型更低的迁移学习预测精度。最接近真实RUL 225小时的平均预测RUL由LSTM模型展示(197.60小时)。由于选择最小RMSE最小的模型作为最佳性能模型，因此1D-CNN-双向GRU模型在FC2上表现出最佳整体预测性能。图10描述了每个所提模型在FC2上直接训练的测试阶段预测绝对百分比误差随测试时间的变化。由于所有模型在训练和验证阶段的预测误差在相应阶段结束时收敛到零，因此未展示训练和验证预测误差。这些图是每个模型一次训练-验证-测试迭代的结果，由于神经网络的随机权重和偏置，每次迭代可能不同。从图中可以推断，对于所有模型，由于图4(c)中电堆输出电压的突然峰值，误差图在850小时左右出现尖锐峰值。然而，绝对百分比误差未超过0.40，清楚地表明所提预测模型在直接训练中表现出鲁棒的预测性能。

[图8 - FC2的预测电堆电压曲线]

[表5 - FC2数据集在50次迭代上的预测结果(真实RUL=225h)]

[图9 - 1D-CNN-双向GRU模型在FC2上直接训练和对FC1迁移学习的RMSE、MAPE、MAE、R^2]

[图10 - FC2直接训练的绝对百分比误差]

4.4 迁移学习结果

在第4.2和4.3节中，分析了两组（FC1和FC2）六个模型的长期退化趋势和RUL预测性能。为了节省计算资源并提高泛化能力，深度学习模型可以在一个数据集上训练，然后

通过迁移学习用于预测另一个数据集的观测值。每个在FC1上训练的深度学习模型在FC2上进行长期退化和RUL预测，以分析静态负载下开发的模型对动态负载的泛化能力。使用表2中列出的最优超参数在FC1上训练的六个模型，在FC2验证集和测试集上进行验证和测试。六种模型的退化趋势和RUL预测结果如图11和表6所示。图11的电压曲线不连续，因为训练集来自FC1数据集，而验证集和测试集来自FC2数据集。表6中的损失指标表明，通过迁移学习开发的模型比第4.2节中的模型更准确和可靠。然而，迁移学习模型的预测精度（即开发模型的泛化能力）取决于训练集和测试集之间的相似性。FC1和FC2数据集来自具有相同特性但负载条件不同的PEMFC电堆。此外，两个电堆遵循相似的电压退化趋势，但在不同时间具有不同的峰值。LSTM模型展示了最佳最小和平均RMSE，分别为1.555E-3和2.455E-3，而GRU模型展示了最佳最小MAPE 0.346E-1。LSTM模型还展示了最佳平均MAPE和R^2，分别为0.630E-1和98.91E-2。GRU、1D-CNN-LSTM、1D-CNN-双向LSTM和1D-CNN-双向GRU模型展示了最小的RUL估计RE 0.0。然而，最佳平均RUL估计RE 0.697E-1和最接近真实RUL 225小时的RUL预测(210.18小时)由LSTM模型展示。添加CNN层增加了LSTM模型的平均RMSE，但降低了GRU模型的平均RMSE。根据这些结果，可以得出结论，LSTM模型在迁移学习方面表现最佳。图12展示了每个所提模型在FC1上直接训练并迁移到FC2的测试阶段绝对百分比预测误差。如前所述，未展示训练和验证误差。从图中可以看出，迁移学习误差图比直接训练误差图滞后，因为FC1的预测时间范围是从692小时到1154小时，而FC2是从612小时到1020小时。观察到所有模型的迁移学习和直接训练绝对百分比误差均未超过0.40。另一个观察是，对于1D-CNN-双向LSTM和1D-CNN-双向GRU模型，迁移学习绝对百分比误差大多高于直接训练绝对百分比误差。总体而言，误差图表明所有模型在直接训练和迁移学习性能上都是鲁棒的。

[图11 - 迁移学习的预测电堆电压曲线]

[表6 - 迁移学习预测结果(50次迭代，真实RUL=225h)]

[图12 - 迁移学习的绝对百分比误差]

4.5 与近期工作的比较

将所提模型中针对FC1和FC2的最佳预测模型（分别为LSTM和1D-CNN-双向GRU）与四项采用IEEE PHM 2014数据挑战数据集进行模型开发和验证的近期深度学习预测工作进行比较。值得注意的是，一些工作未报告其评估指标值是多次训练迭代的平均值、中位数还是最小值。此外，大多数模型未报告使用独立于测试集的验证集进行模型训练。而且，只有少数工作报道了是否进行了多次独立训练迭代以获得最小、最大和平均预测结果。另外，由于数据预处理方法的差异，实际RUL有所不同，因此仅使用RUL估计RE进

行比较。因此，将两个最佳模型（FC1的LSTM和FC2的1D-CNN-双向GRU）的最佳（最小）RMSE、MAPE和RUL预测RE与文献中报道的相应指标进行比较。表7显示了所提模型与以下工作的比较结果：双向LSTM with attention [24]、双向LSTM-GRU with ESN [25]、LSTM-SVR-RF ensemble [26]和dilated CNN [28]。与文献[24-26,28]相比，所提模型在FC1和FC2上均表现出更小的RMSE，并且MAPE也小于文献[24,26,28]的报告。所提模型的优越性能归因于使用TPE和Hyperband剪枝进行的智能超参数优化。然而，所提模型的最佳RUL预测RE比其他模型至少小一个数量级（文献[26]除外）。由于比较的工作均未考虑迁移学习，所提模型的迁移学习结果无法比较。因此，所提模型提供了比其它模型更好的RUL和长期退化预测性能。

[表7 - 所提模型与近期工作的平均预测结果比较]

5. 结论

本文提出了一种基于深度学习的预测方法，用于预测静态和动态负载下五电芯质子交换膜燃料电池(PEMFC)电堆的长期退化趋势和剩余使用寿命(RUL)。首先，使用Python的Keras库开发了以下六种深度学习预测模型：LSTM、1D-CNN-LSTM、1D-CNN-双向LSTM、GRU、1D-CNN-GRU和1D-CNN-双向GRU。每个模型的超参数使用Optuna中开源的树状结构Parzen估计器(TPE)和Hyperband剪枝进行调优。每个模型的性能在IEEE PHM 2014数据挑战数据集上进行了验证。预测结果表明，所提深度学习架构能够实现比现有文献中大多数深度学习模型更准确的退化和RUL预测。测试结果表明，FC1的最佳模型(LSTM)的最佳R^2、RMSE、MAPE和RE分别为98.87E-2、1.26E-3、0.285E-1和0.0425E-1。FC2的最佳模型(CNN-双向GRU)的最佳R^2、RMSE、MAPE和RE分别为99.48E-2、1.77E-3、0.444E-1和0.089E-1。FC1的最佳模型(LSTM)在FC2上也显示出优异的迁移学习结果，最佳R^2、RMSE、MAPE和RE分别为98.91E-2、0.362E-1、2.042E-3和0.044E-1。由于所提方法不假设PEMFC的特定运行模式，因此可以探索将其用于在各种负载条件下记录的其他燃料电池数据集。未来的研究还可以探索具有循环和卷积层的深度学习模型集成，并在低计算时间与高RUL和长期退化趋势预测精度之间取得平衡。另一个研究方向是提取容易获得的电堆测量值作为特征来训练深度学习模型，并将这些模型与状态估计器集成以用于不可用的测量值。此外，自主代理可以根据在线退化预测结果对预测性维护动作进行分类。

致谢

作者感谢Netaji Subhas University of Technology（印度新德里）人工智能卓越中心提供NVIDIA DGX A100 GPU访问权限，以加速本工作中深度学习模型的开发。

缩略语

CNN: 卷积神经网络; GRU: 门控循环单元; GWO: 灰狼优化器; EI: 期望改进; ESN: 回声状态网络; LSTM: 长短期记忆; MAE: 平均绝对误差; MAPE: 平均绝对百分比误差; PEMFC: 质子交换膜燃料电池; PHM: 预测与健康管理; PSO: 粒子群优化; RE: 相对误差; RMSE: 均方根误差; RNN: 循环神经网络; RUL: 剩余使用寿命; SGF: Savitzky-Golay滤波器; TPE: 树状结构Parzen估计器。

参考文献

[1] Wang G, Yu Y, Liu H, et al. Progress on design and development of polymer electrolyte membrane fuel cell systems for vehicle applications: a review. Fuel Process Technol 2018;179:203-28.
[2] Zakaria Z, Kamarudin SK, Abd Wahid KA, et al. The progress of fuel cell for malaysian residential consumption... Renew Sustain Energy Rev 2021;144:110984.
...（为简洁，此处仅列出部分，完整参考文献参见原文）

© 2023 Hydrogen Energy Publications LLC. 由Elsevier Ltd.出版。中文翻译仅供学术参考。